Politechnika Rzeszowska im. Ignacego Łukasiewicza

Optymalizacja Nieliniowa

Optymalizacja wielowymiarowa metodą Rosenbrocka

Dokumentacja

Autor: Marcin Kapanowski | Marek Karbarz

Nr albumu: 176809 | 176810

Rzeszów, 2026

Spis treści

1 Wprowadzenie **2**

1.1 Funkcja celu . . . 2

1.2 Ograniczenia dziedziny . . . 3

2 Opis zadania **3**

3 Metoda Rosenbrocka **4**

3.1 Kierunki (baza) . . . 4

3.2 Reguła kroku: α i β . . . 4

3.3 Rotacja bazy (Gram–Schmidt) . . . 4

3.4 Warunek stopu . . . 5

4 Eksperyment **5**

4.1 Starty losowe . . . 5

4.2 Trzy zestawy parametrów . . . 5

4.3 Maksymalizacja przez minimalizację . . . 5

5 Wyniki **6**

5.1 Minimalizacja — podsumowanie . . . 6

5.2 Maksymalizacja — podsumowanie . . . 8

5.3 Wpływ parametrów na koszt obliczeń . . . 10

6 Excel **11**

6.1 `_wyniki` . . . 11

6.2 `_wartości_średnie` . . . 11

6.3 `_wykresy` . . . 11

7 Fragmenty kodu **12**

7.1 Funkcja celu i ograniczenia dziedziny . . . 12

7.2 Reguła kroku (sukces/porażka) — serce metody . . . 12

7.3 Zmienne `delta`, `d` i `a`? . . . 13

7.4 Rotacja bazy (Gram–Schmidt) . . . 13

7.5 Eksport . . . 13

8 Wnioski końcowe **14**

1 Wprowadzenie

Celem projektu było znalezienie minimum oraz maksimum zadanej funkcji dwóch zmiennych na ograniczonej dziedzinie $[-1, 1] \times [-1, 1]$, przy użyciu metody bezgradientowej (bez liczenia pochodnych) — metody Rosenbrocka.

W praktyce oznacza to:

- start z losowego punktu $(x_1^{(0)}, x_2^{(0)})$,
- wykonywanie próbnych kroków w kilku kierunkach,
- akceptowanie tylko kroków, które poprawiają wartość funkcji,
- adaptację kroku (przyspieszanie po sukcesie i zwalnianie po porażce),
- okresową zmianę/rotację bazy kierunków (żeby lepiej dopasować się do „dolin” i „grzbietów” funkcji).

1.1 Funkcja celu

Optymalizowana funkcja w zadaniu:

$$f(x, y) = x^2 - y^2 - \cos(1.8\pi x) - \cos(1.6\pi(y - 0.5)) + 3.$$

Ważna intuicja: składniki cosinusowe powodują falowanie funkcji, przez co funkcja ma wiele ekstremów lokalnych. To oznacza, że algorytm może trafić do różnych minimów/maksimów lokalnych w zależności od punktu startowego.

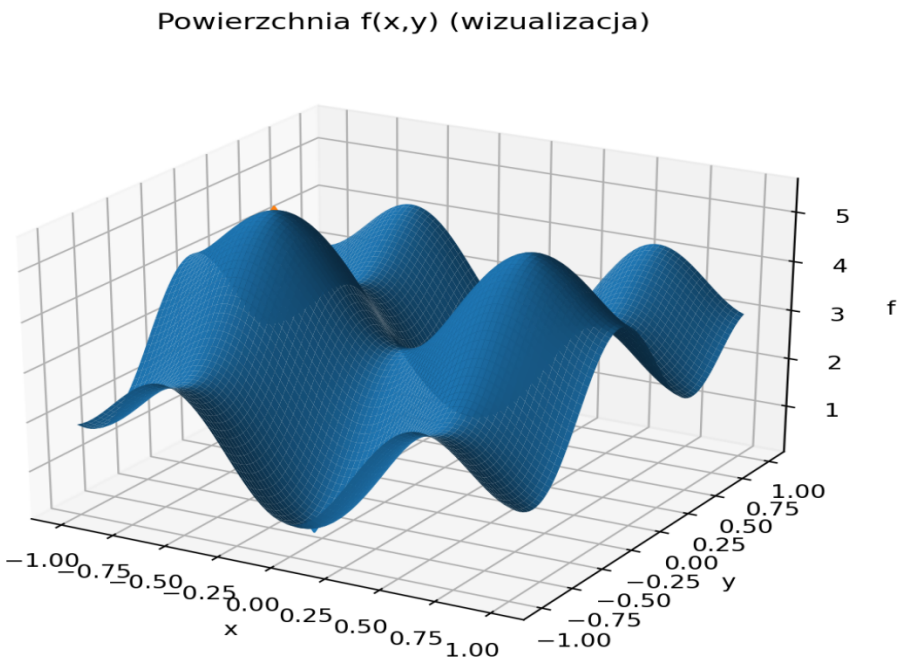

Rysunek 1: Wizualizacja funkcji celu

1.2 Ograniczenia dziedziny

Wszystko liczymy na obszarze:

$$(x, y) \in [-1, 1] \times [-1, 1].$$

W kodzie kontrolujemy to przez funkcje z „karą” (jeśli algorytm wyjdzie poza dziedzinę, zwracamy ∞).

2 Opis zadania

1. Zaimplementować metodę Rosenbrocka (bez gradientu).
2. Przetestować ją na funkcji $f(x, y)$ w $[-1, 1] \times [-1, 1]$.
3. Uruchomić algorytm z **100 losowych punktów startowych** w $[-1, 1] \times [-1, 1]$.
4. Powtórzyć eksperyment dla 3 zestawów parametrów:

$$(\alpha, \beta) \in \left\{(2, \tfrac{1}{2}),\ (3, \tfrac{1}{3}),\ (4, \tfrac{1}{4})\right\}.$$

5. Osobno wykonać:
   - **minimalizację** $f(x, y)$,
   - **maksymalizację** $f(x, y)$ (w kodzie: minimalizacja $-f(x, y)$).
6. Zapisać wyniki do Excela w arkuszach: `_wyniki`, `_wartości_średnie`, `_wykresy`.

3 Metoda Rosenbrocka

Metoda Rosenbrocka jest metodą bezgradientową, która działa na zasadzie: **spróbuj krok, zobacz czy lepiej; jeśli tak — idź dalej; jeśli nie — zawróć i zmniejsz krok**.

3.1 Kierunki (baza)

W 2D mamy dwa kierunki (dwie osie bazy). Startowo to zwykle:

$$d_1 = (1, 0), \quad d_2 = (0, 1).$$

W trakcie działania baza jest **obracana**, aby lepiej pasowała do tego, jak wygląda funkcja w okolicy (np. gdy minimum leży w wąskiej „dolinie" pod skosem).

3.2 Reguła kroku: α i β

Kroki są adaptacyjne:

- sukces (dla min: f spadło) $\Rightarrow \Delta \leftarrow \alpha\Delta$,
- porażka (dla min: f wzrosło) $\Rightarrow \Delta \leftarrow -\beta\Delta$ (minus oznacza próbę w drugą stronę).

Co to daje w praktyce?

- większe α = bardziej agresywne przyspieszanie po sukcesie,
- mniejsze β (u nas $\beta = 1/\alpha$) = mocniejsze hamowanie po porażce,
- zwykle większe α zwiększa koszt (więcej prób), ale pomaga „dociągnąć" do ekstremum.

3.3 Rotacja bazy (Gram–Schmidt)

Po przejściu kroków w bieżącej bazie wiemy, w jakim kierunku realnie przesuwaliśmy się w przestrzeni. Ustawiamy więc nowe kierunki zgodnie z ruchem i ortogonalizujemy je (Gram–Schmidt), aby:

- kierunki były niezależne (prostopadłe),
- obliczenia były stabilne,
- algorytm lepiej trafiał w „dolinę"/„grzbiet".

3.4 Warunek stopu

Algorytm kończy działanie, gdy kroki zrobią się wystarczająco małe:

$$\max_i |\Delta_i| \leq \varepsilon$$

albo gdy przekroczymy limit iteracji.

4 Eksperyment

4.1 Starty losowe

Wygenerowano 100 punktów startowych:

$$x_1^{(0)}, x_2^{(0)} \sim U(-1, 1).$$

4.2 Trzy zestawy parametrów

Uruchomiono metodę osobno dla:

$$(\alpha, \beta) = (2, \tfrac{1}{2}),\ (3, \tfrac{1}{3}),\ (4, \tfrac{1}{4}).$$

4.3 Maksymalizacja przez minimalizację

Maksimum f znaleziono przez minimalizację:

$$g(x, y) = -f(x, y).$$

Wtedy:

$$f(x^*, y^*) = -g(x^*, y^*).$$

Ważny szczegół: Po wyjściu poza $[-1, 1] \times [-1, 1]$ funkcja ograniczona zwraca ∞. Tak samo dla maksymalizacji (czyli w g) też zwracamy ∞. Dzięki temu algorytm **nie ucieka poza dziedzinę**.

5 Wyniki

5.1 Minimalizacja — podsumowanie

Tabela 1: Minimalizacja — wartości średnie i liczba wystąpień

Parametry	Rodzaj	$\overline{x_1^*}$	$\overline{x_2^*}$	$\overline{y^*}$	$\overline{L_f}$	$\overline{L_b}$	Liczba
2, 1/2	Minimum globalne	0.000000	-0.815765	0.388670	88.33	13.22	27
2, 1/2	Minimum lokalne	0.082192	0.254080	1.386474	90.78	13.37	73
2, 1/2	Brak zbieżności						0
3, 1/3	Minimum globalne	0.000000	-0.815765	0.388670	94.59	17.66	29
3, 1/3	Minimum lokalne	0.098591	0.272593	1.338454	93.54	17.27	71
3, 1/3	Brak zbieżności						0
4, 1/4	Minimum globalne	-0.000000	-0.815765	0.388670	102.31	20.72	29
4, 1/4	Minimum lokalne	0.140845	0.296341	1.238866	99.06	19.79	71
4, 1/4	Brak zbieżności						0

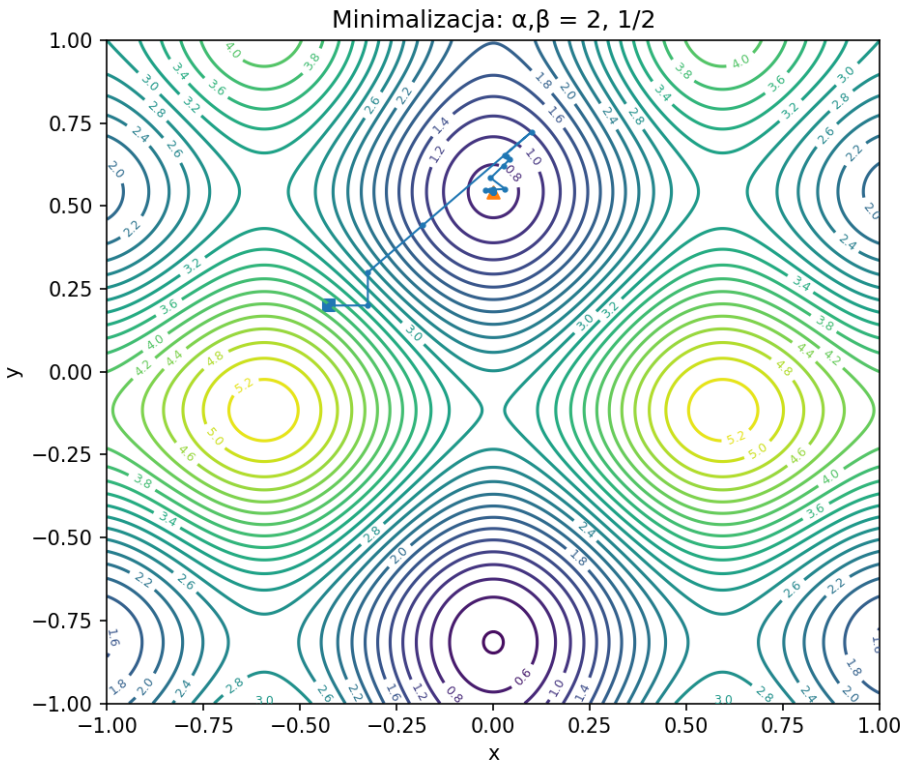

Rysunek 2

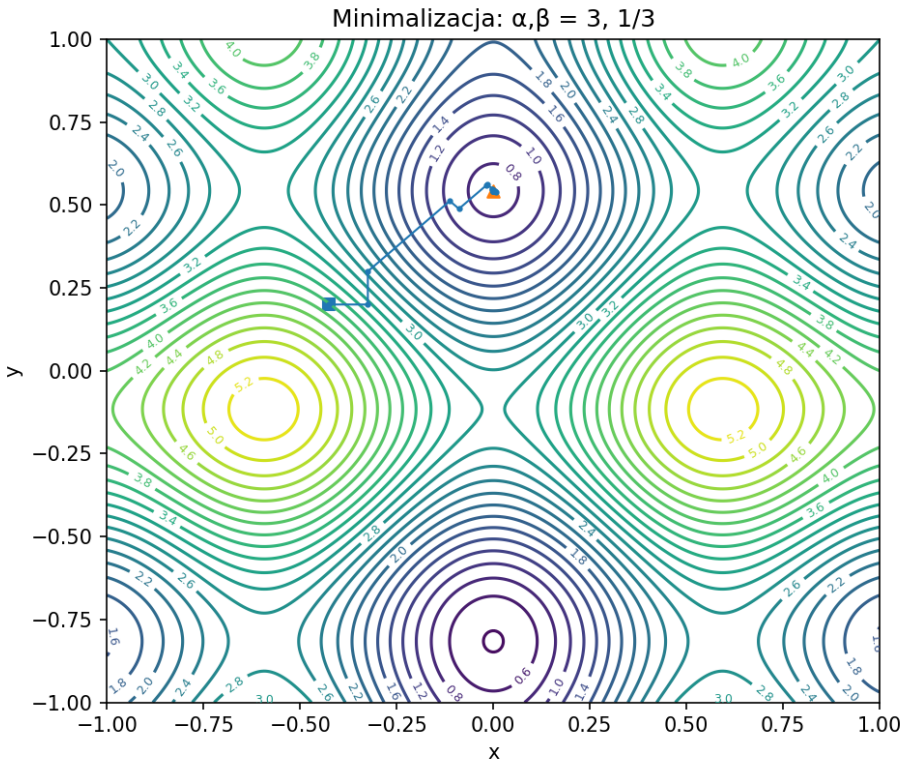

Rysunek 3

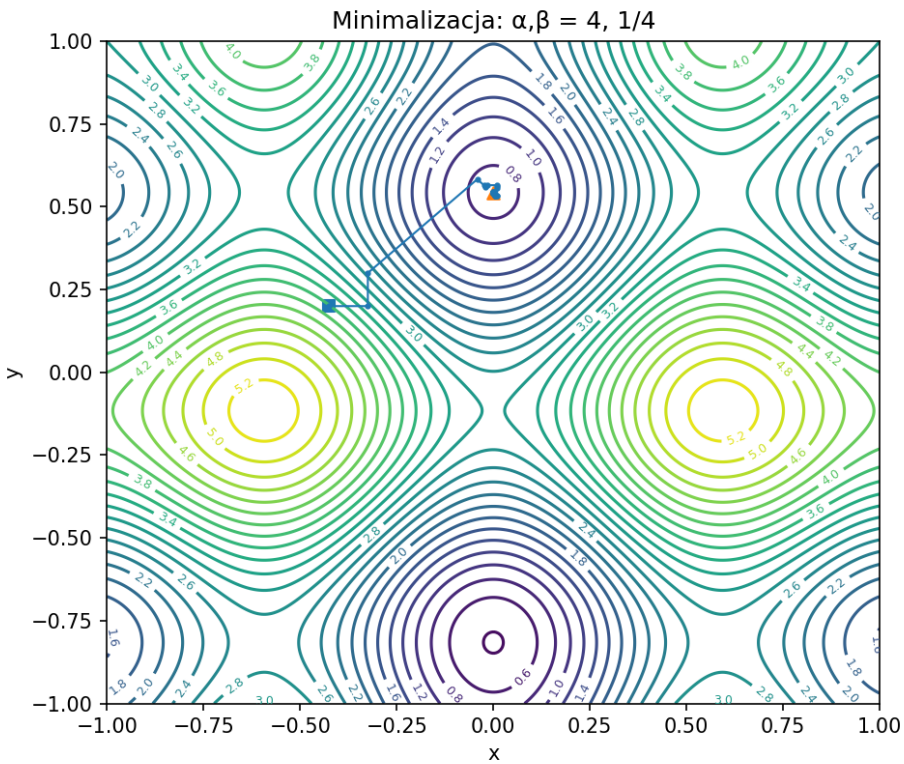

Rysunek 4

Najlepsze znalezione minimum:

$$f(x^*, y^*) \approx 0.388670 \quad \text{w punkcie} \quad (x^*, y^*) \approx (-0.000000,\ -0.815765).$$

Interpretacja: W minimum globalne trafiamy w ok. 27–29% startów (zależnie od parametrów), natomiast pozostałe starty kończą się w minimum lokalnym. To jest normalne dla funkcji z wieloma „dolinami” lokalnymi.

5.2 Maksymalizacja — podsumowanie

Tabela 2: Maksymalizacja — wartości średnie i liczba wystąpień

Parametry	Rodzaj	$\overline{x_1^*}$	$\overline{x_2^*}$	$\overline{y^*}$	$\overline{L_f}$	$\overline{L_b}$	Liczba
2, 1/2	Maksimum globalne	0.060812	-0.115828	5.314836	84.85	12.36	78
2, 1/2	Maksimum lokalne	-0.040679	0.818182	4.024366	77.36	9.82	22
2, 1/2	Brak zbieżności						0
3, 1/3	Maksimum globalne	0.060812	-0.115828	5.314836	92.03	17.00	78
3, 1/3	Maksimum lokalne	-0.042582	0.818181	4.024550	84.64	15.18	22
3, 1/3	Brak zbieżności						0
4, 1/4	Maksimum globalne	0.091218	-0.115828	5.314836	99.51	19.78	78
4, 1/4	Maksimum lokalne	-0.053680	0.818181	4.033014	87.73	16.86	22
4, 1/4	Brak zbieżności						0

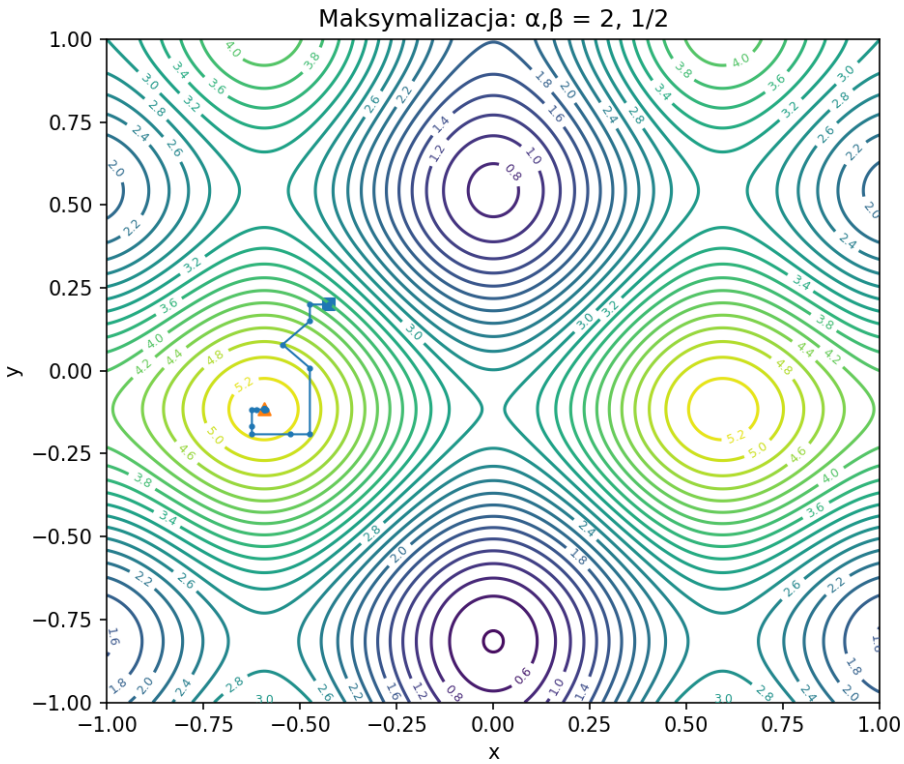

Rysunek 5

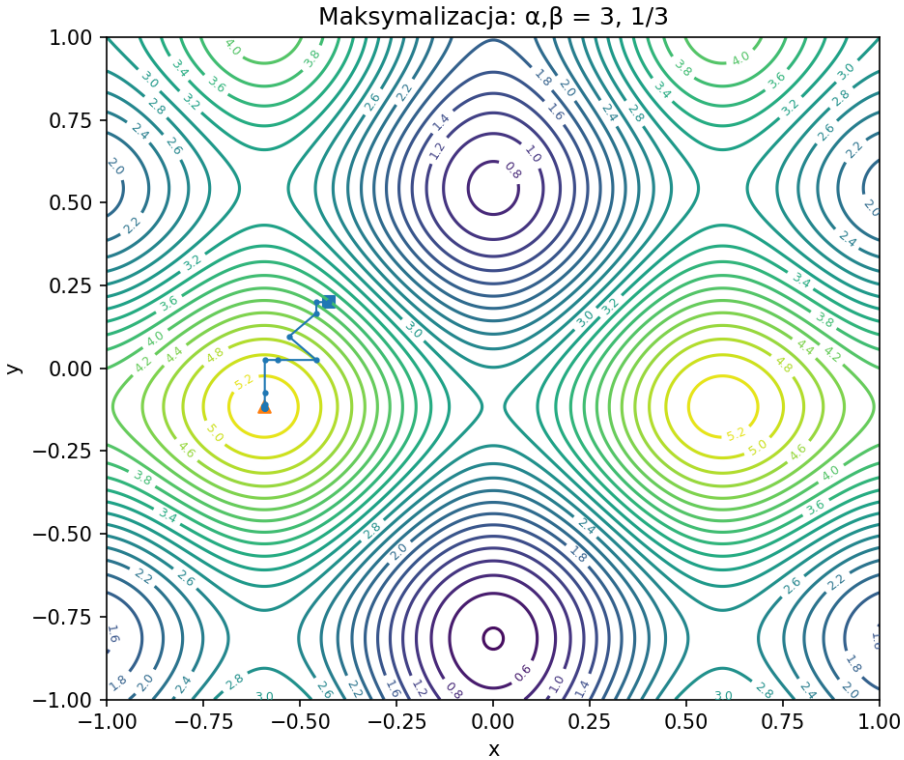

Rysunek 6

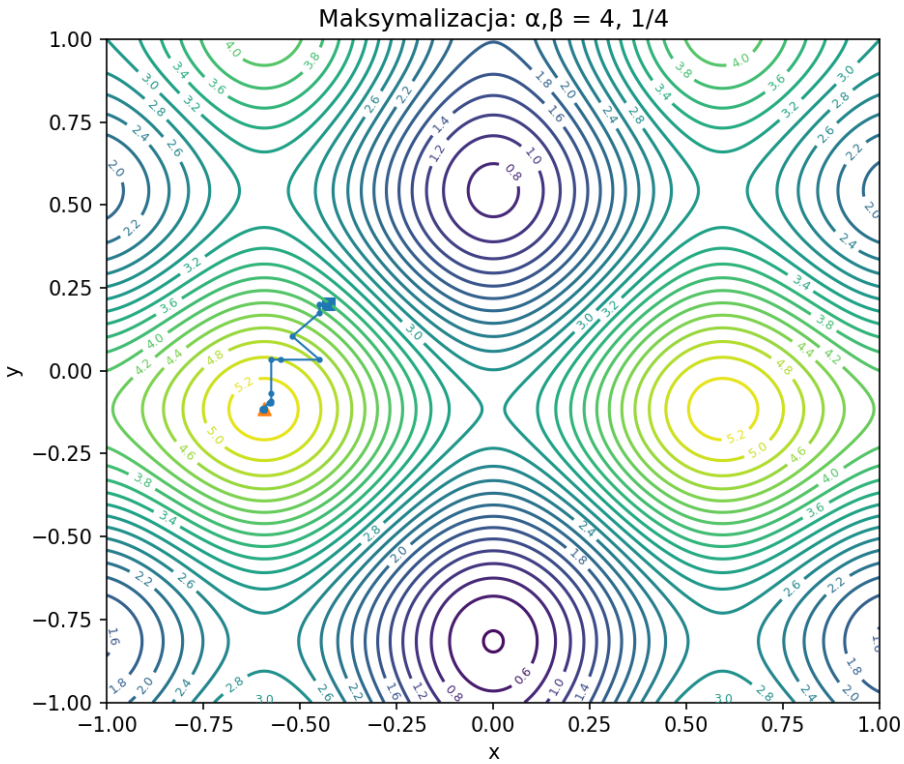

Rysunek 7

Najlepsze znalezione maksimum (z arkusza `_wyniki`):

$$f(x^*, y^*) \approx 5.314836 \quad \text{w punkcie} \quad (x^*, y^*) \approx (-0.592916,\ -0.115828).$$

Ważna uwaga o średnich w maksimum globalnym: Maksimum globalne pojawia się w dwóch symetrycznych punktach $(\pm 0.592916,\ -0.115828)$. Dlatego średnia $\overline{x_1^*}$ może wyjść blisko zera (dodatnie i ujemne wartości znoszą się), mimo że prawdziwe punkty maksymalne są oddalone od zera.

5.3 Wpływ parametrów na koszt obliczeń

Z tabel widać trend: większe α (a więc mniejsze β) zwykle zwiększa $\overline{L_f}$ oraz $\overline{L_b}$. Częstość trafień w ekstrema globalne zwykle zmienia się niewiele.

6 Excel

6.1 `_wyniki`

Każdy wiersz to jedno uruchomienie algorytmu.

- **x1(0), x2(0)** – punkt startowy.
- **x1*, x2*** – punkt końcowy (wynik algorytmu).
- **y*** – wartość funkcji w punkcie końcowym.
- **L.wywołań** – ile razy policzono funkcję (koszt).
- **L.zmian bazy** – ile razy obracano bazę (rotacje).
- **Typ ekstremum** – globalne / lokalne / brak zbieżności.

6.2 `_wartości_średnie`

Podsumowanie:

- średnie $\overline{x_1^*}, \overline{x_2^*}, \overline{y^*}$,
- średni koszt $\overline{L_f}$ i $\overline{L_b}$,
- liczba trafień w dane ekstremum.

6.3 `_wykresy`

Wykresy poziomic + trajektorie. Na nich widać:

- duże skoki na początku (duże kroki),
- później dociskanie w okolice ekstremum (kroki maleją),
- różnice w zachowaniu dla różnych (α, β).

7 Fragmenty kodu

7.1 Funkcja celu i ograniczenia dziedziny

```
f_raw <- function(x, y) {
  x^2 - y^2 - cos(1.8*pi*x) - cos(1.6*pi*(y - 0.5)) + 3
}

f_constrained <- function(v) {
  if (any(!is.finite(v)) || any(abs(v) > 1)) return(Inf)
  f_raw(v[1], v[2])
}

g_constrained <- function(v) {
  if (any(!is.finite(v)) || any(abs(v) > 1)) return(Inf)
  -f_raw(v[1], v[2])
}
```

Listing 1: Funkcja celu i ograniczenia: poza dziedziną kara = Inf

Opis: „Dajemy karę ∞ poza $[-1, 1]^2$, więc algorytm nie może tam uciekać. Maksymalizację robimy przez minimalizację $-f$, ale kara zostaje ∞, żeby nie generować sztucznego $-\infty$."

7.2 Reguła kroku (sukces/porażka) — serce metody

```
x_trial <- x + delta[i] * d[i,]
f_trial <- f(x_trial)

if (is.finite(f_trial) && f_trial < f_current) {
  x <- x_trial
  f_current <- f_trial
  a[i] <- a[i] + delta[i]
  delta[i] <- delta[i] * alpha
  path <- rbind(path, x)
} else {
  delta[i] <- -beta * delta[i]
}
```

Listing 2: Aktualizacja kroku: sukces -> *alpha, porażka -> -*beta

Opis: „Jak jest lepiej, przyspieszamy. Jak gorzej, hamujemy i próbujemy w drugą stronę."

7.3 Zmienne `delta`, `d` i `a`?

- `delta[i]` — aktualny krok w i-tym kierunku,
- `d[i,]` — i-ty kierunek bazy (wektor kierunku),
- `a[i]` — łączna suma zaakceptowanych przesunięć w i-tym kierunku w jednym cyklu (potem służy do rotacji bazy).

7.4 Rotacja bazy (Gram–Schmidt)

```
A <- matrix(0, n, n)
for (k in n:1) {
  for (j in k:n) {
    A[k,] <- A[k,] + a[j] * d[j,]
  }
}

d_new <- gram_schmidt_complete(A, fallback = d, tol = 1e-12)
if (!is.null(d_new)) {
  d <- d_new
  delta <- abs(delta)
  basis_changes <- basis_changes + 1
}
```

Listing 3: Budowanie nowej bazy z przesunięć + ortogonalizacja

Opis: „Po cyklu kroków ustawiamy nowe kierunki zgodnie z ruchem. Gram–Schmidt robi kierunki prostopadłe, żeby metoda była stabilna.”

7.5 Eksport

W arkuszu `_wyniki` zapisujemy:

- start $(x_1^{(0)}, x_2^{(0)})$,
- wynik (x_1^*, x_2^*) i y^*,
- koszt: `L.wywołań` i `L.zmian bazy`,
- typ ekstremum (globalne/lokalne/brak zbieżności).

Arkusz `_wartości_średnie` to agregacja (średnie + liczebności).

8 Wnioski końcowe

1. Metoda Rosenbrocka działa poprawnie jako metoda bezgradientowa na dziedzinie ograniczonej.

2. Dla minimalizacji często trafiamy w minimum lokalne, a rzadziej w globalne — bo funkcja ma wiele lokalnych dolin.

3. Dla maksymalizacji najczęściej trafiamy w maksimum globalne.

4. Zwiększenie α zwiększa koszt obliczeń ($\overline{L_f}$ i $\overline{L_b}$), ale nie zmienia radykalnie częstości trafień.

5. Dla maksimum globalnego pamiętamy o symetrii $(\pm x^*, y^*)$, więc średnia $\overline{x_1^*}$ może być myląca.