Metoda Rosenbrocka – notatki do prezentacji

Ćwiczenie projektowe 3: optymalizacja wielowymiarowa bez gradientu

Dokument pomocniczy: co było zadaniem, jak działa algorytm i jak czytać wyniki.

Data: 2026-01-27

Tip: czytaj to jak scenariusz – wiele fragmentów jest gotowych do powiedzenia na głos.

O czym jest projekt (jednym zdaniem)

Mamy funkcję dwóch zmiennych na kwadracie [-1,1]x[-1,1] i szukamy jej minimów oraz maksimów metodą bezgradientową (Rosenbrocka), porównując zachowanie algorytmu dla trzech par parametrów (alpha, beta).

Spis treści

1. Co było zadaniem i co oddajemy
2. Funkcja celu: jak ją czytać i czemu ma wiele ekstremów
3. Minimum, maksimum, lokalne vs globalne (intuicja)
4. Metoda Rosenbrocka: idea i przebieg krok po kroku
5. Parametry alpha i beta: co sterują i jak wpływają
6. Minimalizacja i maksymalizacja w praktyce (trik z -f)
7. Eksperyment: 100 losowych startów – po co i czego się spodziewać
8. Jak czytać plik Excel (_wyniki, _wartości_średnie, _wykresy)
9. Jak to jest zrobione w index.Rmd (mapa kodu)
10. Najczęstsze pytania na prezentacji + gotowe odpowiedzi
11. Mini-scenariusz prezentacji (2–5 minut) + ściąga

1. Co było zadaniem i co oddajemy

W poleceniu dostaliśmy funkcję celu f(x,y) oraz wymaganie, żeby znaleźć jej ekstrema (minima i maksima) na obszarze [-1,1]x[-1,1] metodą Rosenbrocka (metoda bezpośredniego przeszukiwania).

Wymagania z polecenia:

• 3 zestawy parametrów: (alpha=2, beta=1/2), (alpha=3, beta=1/3), (alpha=4, beta=1/4).

• 100 losowych punktów startowych z kwadratu [-1,1]x[-1,1].

• Osobno wyniki dla minimalizacji i maksymalizacji (w pliku xlsx, arkusz _wyniki).

• Osobno wartości średnie (w arkuszu _wartości_średnie).

• Dla jednego wybranego punktu startowego: 3 wykresy poziomic z naniesioną trajektorią punktów (arkusz _wykresy).

Ten projekt jest bardziej o zachowaniu algorytmu niż o jednym numerze. Ponieważ funkcja jest pofałdowana (ma wiele lokalnych ekstremów), punkt startowy ma duże znaczenie.

2. Funkcja celu: jak ją czytać i czemu ma wiele ekstremów

Funkcja celu w zadaniu:

```
f(x,y) = x^2 - y^2 - cos(1.8*pi*x) - cos(1.6*pi*(y - 0.5)) + 3
```

Jak ją rozumieć „po ludzku”:

- x^2 i -y^2 to część „gładka” (paraboloida w dwóch osiach).
- Wyrazy z cos(…) dodają „falowanie” – czyli wiele garbów i dolin.
- +3 to tylko przesunięcie funkcji w górę (nie zmienia miejsc ekstremów, tylko wartości).
- Funkcja jest symetryczna względem x (bo x^2 i cos(…x) są parzyste). Dlatego często maksima/minima występują parami dla +x i -x.

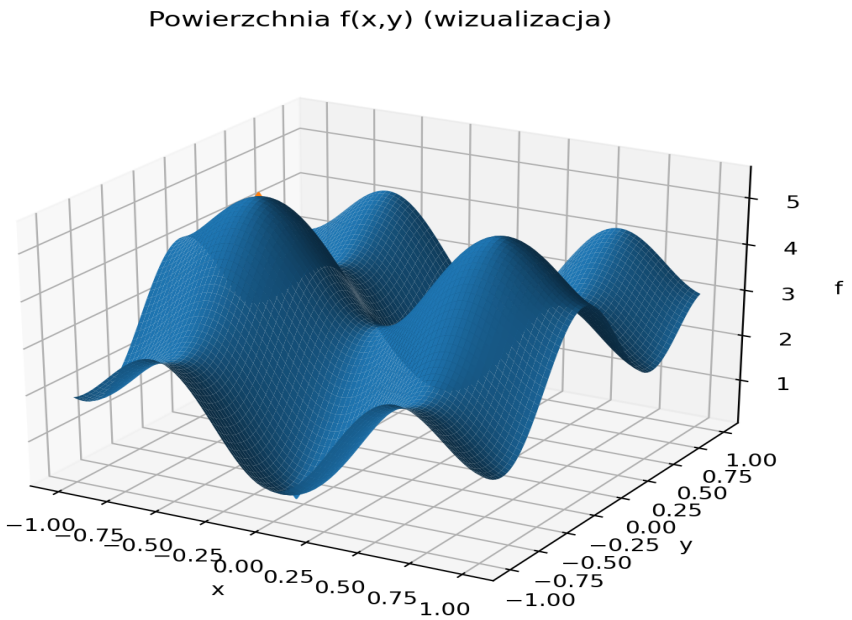

Wizualizacja 3D: powierzchnia f(x,y).

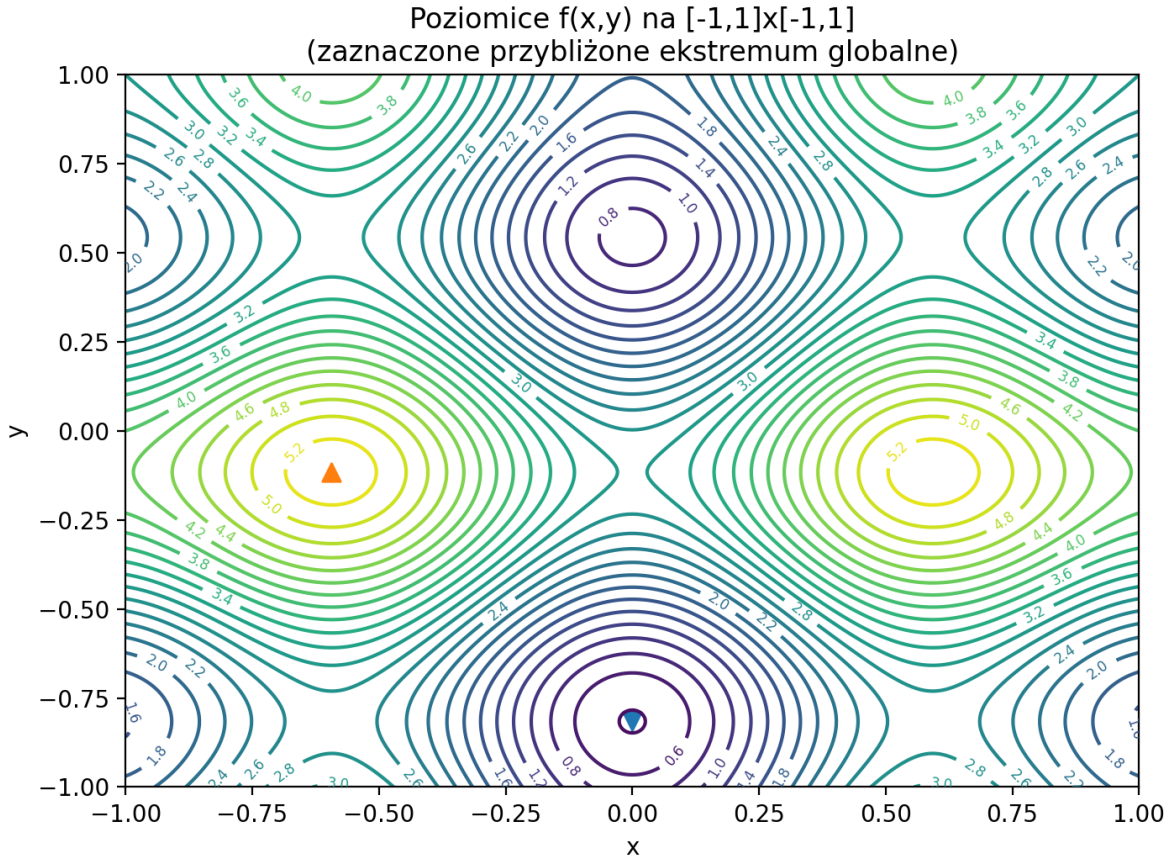

Poziomice (mapa) f(x,y) – na tym rysunku rysujemy trajektorie algorytmu.

Na poziomicach widać różne „baseny” (doliny) i „szczyty”. Wniosek: start z różnych miejsc może doprowadzić do różnych wyników (lokalnych minimów/maksimów).

3. Minimum, maksimum, lokalne vs globalne (intuicja)

Ekstremum to miejsce, gdzie funkcja przestaje „chcieć” iść w dół albo w górę.

Minimum lokalne – w najbliższej okolicy nie da się zejść niżej, ale gdzieś dalej może istnieć niższa dolina.

Minimum globalne – najniższa wartość w całym rozważanym obszarze.

Analogicznie dla maksimum.

Przybliżenia globalnych ekstremów na [-1,1]x[-1,1] (z gęstej siatki):

Ekstremum	Przybliżone (x*, y*)	Wartość f(x*,y*)
Minimum globalne	(0.000, -0.815)	0.388677
Maksimum globalne	(-0.595, -0.115) oraz symetrycznie (0.595, -0.115)	5.314764

W wynikach algorytm powinien często lądować w okolicach tych punktów, albo w innym lokalnym ekstremum (np. minimum lokalne w pobliżu x≈0, y≈0.543).

4. Metoda Rosenbrocka: idea i przebieg krok po kroku

To metoda bezgradientowa (nie liczymy pochodnych). Traktujemy funkcję jak „czarną skrzynkę”: podajemy (x,y), dostajemy liczbę f(x,y).

Intuicja: robimy kroki w pewnych kierunkach. Jeśli krok poprawia wynik, to w tym kierunku próbujemy większych kroków (ekspansja). Jeśli pogarsza – zmniejszamy krok i próbujemy w drugą stronę (kontrakcja).

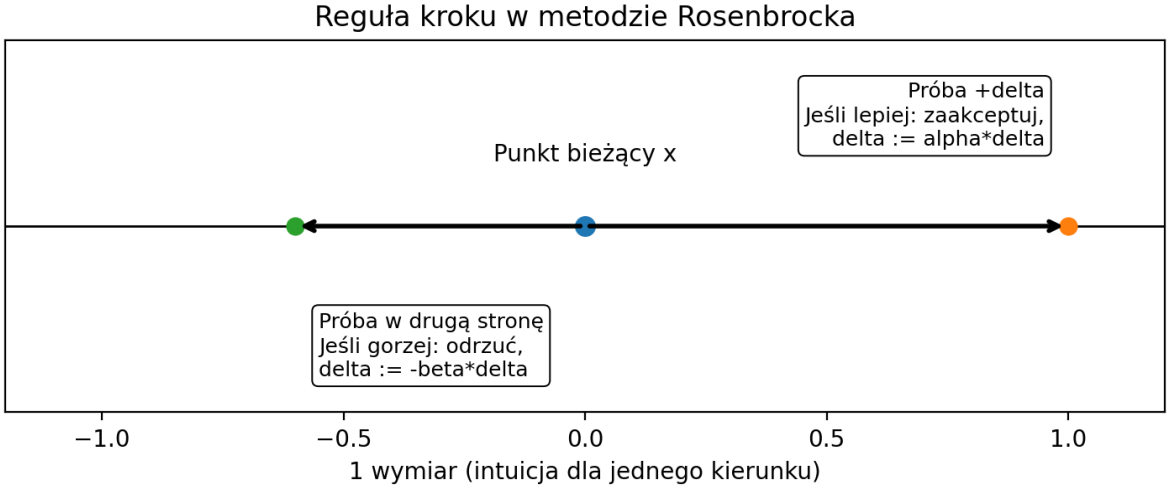

Schemat 1D: zasada zmiany kroku wzdłuż jednego kierunku.

Po przejściu po wszystkich kierunkach algorytm obraca bazę kierunków, żeby lepiej dopasować się do „kierunku postępu”.

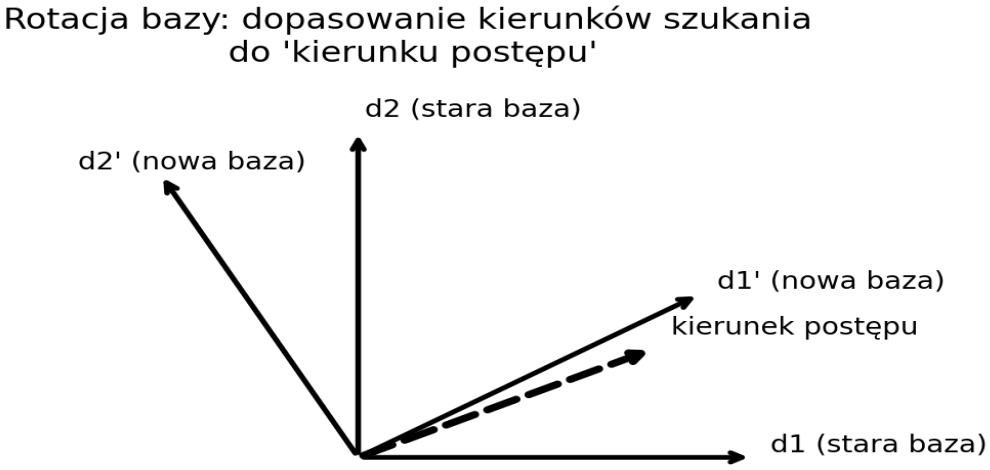

Rotacja bazy: nowe kierunki są wyznaczane z przesunięć i ortogonalizowane (Gram–Schmidt).

Pseudokod (w skrócie):

```
Wejście: punkt startowy x, kroki delta1..deltan, baza kierunków d1..dn
Powtarzaj:
  dla i=1..n:
    spróbuj x_trial = x + delta_i * d_i
    jeśli f(x_trial) < f(x):  (dla minimum)
       x = x_trial
       delta_i = alpha * delta_i
    inaczej:
       delta_i = -beta * delta_i
  jeśli w tym cyklu był sukces:
       zbuduj nowe kierunki z przesunięć (macierz A)
       ortogonalizuj -> nowa baza d
Stop: gdy max(|delta_i|) <= eps albo przekroczono limit iteracji
```

W 2D: „przeskanuj” kierunek 1, potem 2, a potem obróć kierunki tak, żeby pierwszy był bliżej tego, w którym realnie się przesuwasz.

5. Parametry alpha i beta: co sterują i jak wpływają

Dwa kluczowe parametry:

- alpha (> 1) – zwiększa krok po sukcesie.
- beta (0 < beta < 1) – zmniejsza krok po porażce (i odwraca znak).

Testowane pary:

Wariant	alpha	beta	Komentarz intuicyjny
A	2	1/2	umiarkowane przyspieszanie i umiarkowane hamowanie
B	3	1/3	bardziej agresywne kroki, ale też mocniejsze zmniejszanie
C	4	1/4	najbardziej agresywne przy sukcesie, najmocniej tnie po porażce

Większe alpha może przyspieszać, ale zwiększa ryzyko „przestrzelenia”; mniejsze beta daje mocniejsze hamowanie. W pofałdowanym krajobrazie te parametry wpływają na koszt i na to, do którego lokalnego ekstremum wpadniemy.

6. Minimalizacja i maksymalizacja w praktyce (trik z -f)

Algorytm jest minimalizatorem. Maksymalizację robimy przez g(x) = -f(x).

```
maksymalizuj f(x)  <=>  minimalizuj g(x) = -f(x)
```

Ograniczenie dziedziny: poza [-1,1]x[-1,1] zwracamy +Inf, żeby algorytm nie uciekał poza obszar.

To jest krytyczne: błędne znaki Inf/-Inf potrafią całkowicie zepsuć maksymalizację.

7. Eksperyment: 100 losowych startów – po co i czego się spodziewać

Różne starty są potrzebne, bo funkcja ma wiele lokalnych ekstremów.

Po co 100 startów:

- zobaczyć częstość trafienia w globalne vs lokalne,
- ocenić stabilność (ile 'Brak zbieżności'),
- porównać koszt: średnia liczba wywołań funkcji i zmian bazy.

Ściąga: min globalne ~0.389 ($x \approx 0$, $y \approx -0.816$), min lokalne często ~0.728 ($x \approx 0$, $y \approx 0.543$); max globalne ~5.315 ($x \approx \pm 0.593$, $y \approx -0.116$).

8. Jak czytać plik Excel (_wyniki, _wartości_średnie, _wykresy)

_wyniki: dane surowe dla każdego startu i wariantu.

_wartości_średnie: średnie i liczności rozbite na globalne/lokalne/brak zbieżności.

_wykresy: 3 wykresy poziomic + trajektorie dla jednego wybranego startu.

Kolumna (wyniki)	Co znaczy
x1(0), x2(0)	punkt startowy
x1*, x2*	punkt końcowy algorytmu
y*	wartość funkcji w punkcie końcowym
L.wywołań	koszt: ile razy wywołano f
L.zmian bazy	ile razy obracano bazę kierunków
Typ ekstremum	globalne/lokalne/brak zbieżności

9. Jak to jest zrobione w index.Rmd (mapa kodu)

Poniżej masz „mapę” Waszego kodu: co jest gdzie i po co. To jest super przy prezentacji, bo pozwala powiedzieć: „tu definiujemy algorytm, tu robimy eksperyment, tu zapisujemy wyniki”.

Blok 1: ustawienia i definicje

• Ustawienie ziarna losowości (set.seed), żeby wyniki były powtarzalne.

• Definicja funkcji f(x,y) zgodnie z poleceniem.

• Definicje funkcji f_constrained / g_constrained (zwracają +Inf poza [-1,1]x[-1,1]).

Blok 2: rdzeń algorytmu Rosenbrocka

• Funkcja rosenbrock_optimize(...): realizuje pętlę iteracyjną, aktualizuje x, delta i liczniki.

• Reguła kroku: jeśli jest poprawa -> delta := alpha*delta; jeśli nie -> delta := -beta*delta.

• Rotacja bazy: po „cyklu” po kierunkach, z przesunięć budowana jest macierz A, a następnie Gram–Schmidt daje nową bazę (kolumny d).

Blok 3: klasyfikacja i eksperyment

• Wyznaczenie przybliżonego globalnego min/max na siatce (do klasyfikacji).

• classify_extremum(...): sprawdza, czy wynik jest blisko globalnego (tolerancja), inaczej oznacza jako lokalne.

• Pętla po 3 wariantach parametrów i 100 punktach startowych osobno dla min i max.

Blok 4: zapis do Excela i wykresy

• Arkusz _wyniki: zapis surowych rekordów (start, wynik, y*, liczniki, typ).

• Arkusz _wartości_średnie: grupowanie po (parametry, typ) i wyliczanie średnich + liczności.

• Arkusz _wykresy: poziomice + nałożona trajektoria dla jednego startu (3 warianty).

Jeśli ktoś zapyta „co jest miarą szybkości?” – odpowiadacie: L.wywołań. Jeśli „co pokazuje stabilność?” – liczba przypadków braku zbieżności.

10. Najczęstsze pytania na prezentacji + gotowe odpowiedzi

P: Po co 100 punktów startowych?

O: Funkcja ma wiele lokalnych ekstremów. Chcemy statystycznie zobaczyć, gdzie algorytm zwykle trafia i jak stabilnie działa.

P: Dlaczego nie liczymy pochodnych?

O: To ćwiczenie jest o metodzie bezgradientowej. Czasem pochodne są trudne/niedostępne, a my mamy tylko możliwość wywołać f(x).

P: Co oznaczają alpha i beta?

O: alpha steruje jak bardzo zwiększamy krok po sukcesie. beta steruje jak mocno zmniejszamy krok po porażce (i zwykle odwracamy kierunek).

P: Co oznacza L.wywołań?

O: Ile razy policzyliśmy f(x,y). To przybliżony koszt obliczeń – mniej wywołań zwykle znaczy szybciej.

P: Po co rotacja bazy (L.zmian bazy)?

O: Żeby kierunki szukania lepiej pasowały do kierunku faktycznego zejścia/wejścia. W 2D to jak obrót osi, żeby iść wzdłuż doliny zamiast zygzakiem.

P: Jak stwierdzacie zbieżność?

O: W kodzie: jeśli maksymalny krok |delta| jest mniejszy niż eps (1e-6) albo przekroczymy limit iteracji (max_iter).

P: Skąd wiadomo, że to globalne minimum/maksimum?

O: W kodzie jest prosta klasyfikacja: liczymy przybliżone globalne min/max na gęstej siatce, a potem sprawdzamy, czy wynik jest blisko (z tolerancją).

11. Mini-scenariusz prezentacji + ściąga

Wersja 2 minuty:

1) Mamy funkcję f(x,y) na [-1,1]x[-1,1]. Jest pofałdowana przez cos, więc ma wiele lokalnych ekstremów.

2) Szukamy minimów i maksimów metodą Rosenbrocka – bezgradientowo: próbujemy kroki w kierunkach, po sukcesie zwiększamy krok (alpha), po porażce zmniejszamy i odwracamy (beta).

3) Robimy 100 losowych startów i porównujemy 3 ustawienia (alpha,beta).

4) Wyniki są w Excelu: surowe, średnie i 3 wykresy trajektorii na poziomicach.

5) Wnioski: parametry wpływają na szybkość i na to, jak często trafiamy w optimum globalne vs lokalne.

Wersja 5 minut:

1) Pokazujemy funkcję i jej poziomice: widać doliny i garby. To tłumaczy lokalne minima/maksima.

2) Wyjaśniamy ideę bezgradientową: tylko oceniamy f(x,y), nie liczymy pochodnych.

3) Omawiamy regułę kroku: sukces -> alpha*delta, porażka -> -beta*delta. (Pokazujemy schemat).

4) Omawiamy rotację bazy: po cyklu szukania obracamy kierunki, żeby iść wzdłuż kierunku postępu (mniej zygzaka).

5) Opisujemy eksperyment: 100 startów, 3 parametry. Co porównujemy: trafienia w globalne, liczba wywołań, stabilność.

6) Pokazujemy arkusz _wykresy: trajektoria na poziomicach. To jest najbardziej „namacalne”.

7) Zamykamy wnioskami: które parametry dały najlepszy kompromis (częstość globalnego + koszt).

Ściąga wartości (czy wynik wygląda sensownie?):

- Minimum globalne ~ 0.38868 w okolicy (x≈0.000, y≈-0.815).
- Minimum lokalne często ~ 0.72842 w okolicy (x≈0, y≈0.543).
- Maksimum globalne ~ 5.31476 w okolicy (x≈±0.595, y≈-0.115).
- Jeśli w tabeli pojawiają się NA – to „Brak zbieżności” (limit iteracji / zbyt wolne kroki).